РК1. Вариант 9

Поседкин Никита Михайлович ИУ5-21М

Задача №9. Устранение пропусков методом заполнения «хвостом распределения» для одного числового признака.

Задача №29. Удаление константных и псевдоконстантных признаков.

Дополнительно. Диаграмма рассеяния для пары признаков.

In [1]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.feature_selection import VarianceThreshold

%matplotlib inline
sns.set(style="ticks")
np.random.seed(42)
```

Генерация набора данных

Генерируем синтетический медицинский датасет (500 пациентов) с колонками:

- `age` — возраст пациента (лет)
- `systolic_bp` — систолическое артериальное давление (мм рт. ст.) — **числовой признак с пропусками**
- `bmi` — индекс массы тела
- `glucose` — уровень глюкозы в крови (мг/дл), правосторонний хвост
- `heart_rate` — частота сердечных сокращений (уд/мин)
- `region_code` — код региона (константный признак, все = 1)
- `test_version` — версия теста (псевдоконстантный: 97% значений = 1, остальные = 2)
- `hospital_flag` — флаг клиники (псевдоконстантный: 96% = 0)
- `diagnosis` — целевой признак: наличие заболевания (0/1)

In [2]:
```
n = 500

age        = np.random.randint(20, 80, size=n)
systolic_bp = np.random.normal(loc=130, scale=20, size=n).clip(80, 220)
bmi        = np.random.normal(loc=27, scale=5, size=n).clip(15, 50)
glucose    = np.random.exponential(scale=40, size=n) + 70   # правосторонний хвост
heart_rate = np.random.normal(loc=75, scale=12, size=n).clip(45, 130)
```

```
# Константный и псевдоконстантные признаки
region_code  = np.ones(n, dtype=int)                                          # всегд
test_version = np.where(np.random.rand(n) < 0.97, 1, 2).astype(int)         # 97% =
hospital_flag = np.where(np.random.rand(n) < 0.96, 0, 1).astype(int)        # 96% =

diagnosis  = (0.3*(age > 55) + 0.4*(systolic_bp > 140) +
              0.3*(glucose > 110) > 0.4).astype(int)

# Вносим пропуски (~15%) в systolic_bp
miss_idx = np.random.choice(n, size=int(n * 0.15), replace=False)
systolic_bp_with_na = systolic_bp.copy().astype(float)
systolic_bp_with_na[miss_idx] = np.nan

df = pd.DataFrame({
    'age': age,
    'systolic_bp': systolic_bp_with_na,
    'bmi': bmi,
    'glucose': glucose,
    'heart_rate': heart_rate,
    'region_code': region_code,
    'test_version': test_version,
    'hospital_flag': hospital_flag,
    'diagnosis': diagnosis
})

df.head(10)
```

Out[2]:

	age	systolic_bp	bmi	glucose	heart_rate	region_code	test_version	hospital_f
0	58	140.300954	16.590353	107.765083	46.644811	1	1	
1	71	207.054630	35.482282	91.175097	62.883232	1	1	
2	48	141.417810	28.055087	143.268599	82.429851	1	1	
3	34	152.711313	26.516434	162.112654	99.689946	1	1	
4	62	149.080035	24.275405	87.442419	75.249524	1	1	
5	27	143.027825	28.995681	80.813105	66.263965	1	1	
6	40	123.694615	26.811826	130.660772	72.805243	1	1	
7	58	145.179384	32.516509	82.852645	91.498517	1	1	
8	77	NaN	27.571138	139.177157	67.248430	1	1	
9	38	125.263628	27.751509	92.047732	65.409696	1	1	

In [3]:
```
df.shape
```

Out[3]: (500, 9)

In [4]:
```
df.describe()
```

Out[4]:

	age	systolic_bp	bmi	glucose	heart_rate	region_code	test_versic
count	500.000000	425.000000	500.000000	500.000000	500.000000	500.0	500.0000(
mean	50.396000	130.163424	27.539777	109.834564	75.367495	1.0	1.0320(
std	17.335982	20.134577	4.866449	40.929164	11.633884	0.0	0.1761
min	20.000000	80.000000	15.000000	70.128938	45.000000	1.0	1.0000(
25%	36.750000	116.005490	24.223655	80.994048	67.694295	1.0	1.0000(
50%	51.000000	129.629737	27.634202	98.208572	75.004410	1.0	1.0000(
75%	65.000000	143.591955	30.542591	123.492918	83.059782	1.0	1.0000(
max	79.000000	207.054630	40.161910	326.218915	113.317291	1.0	2.0000(

Задача №9. Устранение пропусков методом «хвоста распределения»

Метод «хвоста распределения» применяется, когда пропуски распределены **не случайно** и нужно явно отделить их от основных значений. Пропуски заполняются значением на крае (хвосте) распределения — аномальным, но в рамках реально наблюдаемого диапазона.

Для нормального распределения: $$ extreme_value = mean + 3 \cdot std $$

Для ассиметричного распределения (через IQR): $$ IQR = Q3 - Q1 $$ $$ extreme_value = Q3 + K \cdot IQR, \quad K = 1.5 \text{ или } 3 $$

Анализ пропусков в признаке `systolic_bp`

In [5]:
```
# Количество и доля пропусков
n_missing = df['systolic_bp'].isnull().sum()
pct_missing = df['systolic_bp'].isnull().mean()
print(f'Пропусков: {n_missing} ({pct_missing:.1%})')
```

```
Пропусков: 75 (15.0%)
```

In [6]:
```
# Смотрим на распределение признака (без пропусков)
df['systolic_bp'].hist(bins=40, edgecolor='black', color='steelblue')
plt.title('Распределение systolic_bp (без пропусков)')
plt.xlabel('Артериальное давление (мм рт. ст.)')
plt.ylabel('Частота')
plt.show()
```

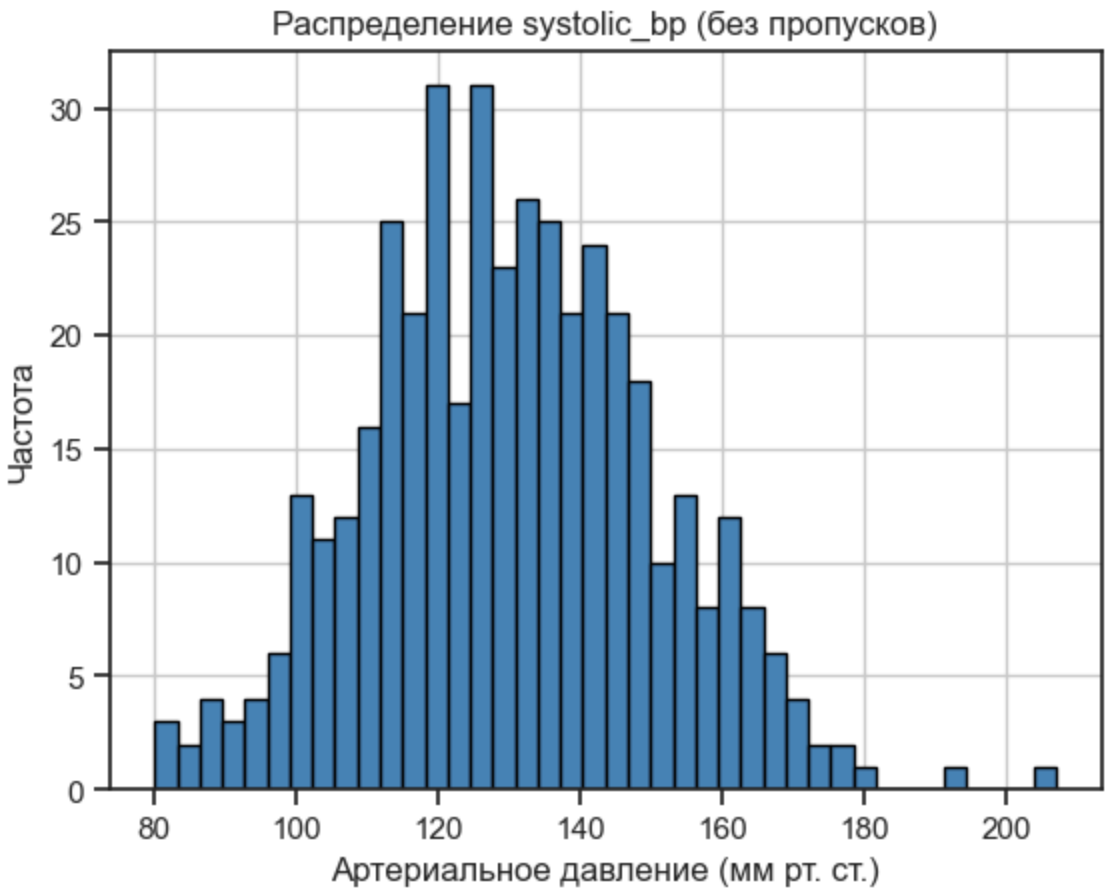

Распределение близко к нормальному, поэтому вычисляем хвост по формуле $mean + 3 \cdot std$.

In [7]:
```
# Вычисляем хвост распределения (нормальный случай)
bp_mean = df['systolic_bp'].mean()
bp_std  = df['systolic_bp'].std()
extreme_value = bp_mean + 3 * bp_std
print(f'mean = {bp_mean:.2f},  std = {bp_std:.2f}')
print(f'extreme_value = {extreme_value:.2f}')
```

```
mean = 130.16,  std = 20.13
extreme_value = 190.57
```

In [8]:
```
# Заполняем пропуски значением хвоста распределения
df_filled = df.copy()
df_filled['systolic_bp'] = df['systolic_bp'].fillna(extreme_value)

print('Пропусков после заполнения:', df_filled['systolic_bp'].isnull().sum())
```

```
Пропусков после заполнения: 0
```

Сравниваем распределения до и после заполнения. Заполненные значения уходят в правый хвост — они выделяются из основного облака и не смешиваются с реальными данными.

In [9]:
```
# Сравнение плотностей распределения до и после заполнения
compare_df = pd.DataFrame({
```

```
    'До заполнения': df['systolic_bp'],
    'После заполнения': df_filled['systolic_bp']
})
sns.kdeplot(data=compare_df)
plt.axvline(extreme_value, color='red', linestyle='--', label=f'extreme_value = {ex
plt.title('KDE: systolic_bp до и после заполнения хвостом распределения')
plt.xlabel('Артериальное давление')
plt.legend()
plt.show()
```

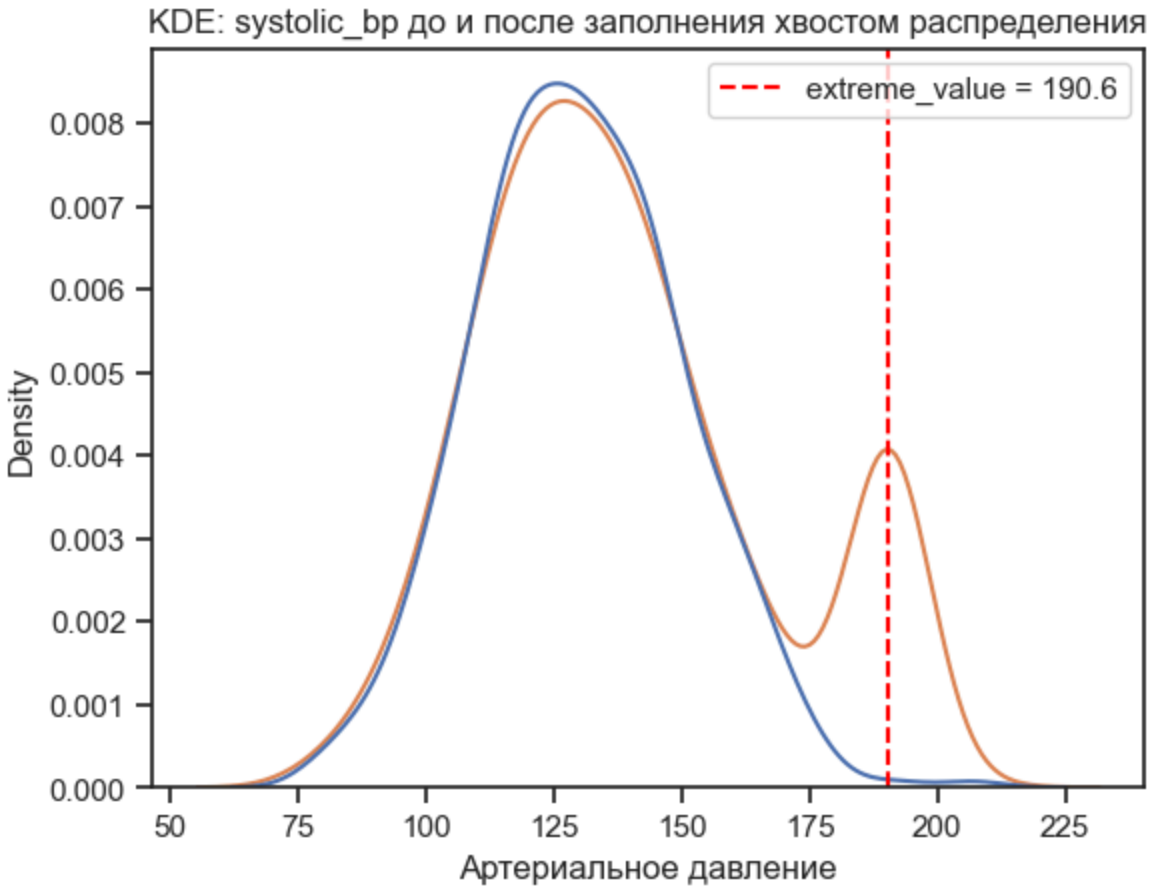

In [10]:
```
# Итоговые статистики
print('Статистики ДО заполнения:')
print(df['systolic_bp'].describe())
print('\nСтатистики ПОСЛЕ заполнения:')
print(df_filled['systolic_bp'].describe())
```

```
Статистики ДО заполнения:
count    425.000000
mean     130.163424
std       20.134577
min       80.000000
25%      116.005490
50%      129.629737
75%      143.591955
max      207.054630
Name: systolic_bp, dtype: float64

Статистики ПОСЛЕ заполнения:
count    500.000000
mean     139.223983
std       28.471025
min       80.000000
25%      118.478870
50%      134.304385
75%      155.025834
max      207.054630
Name: systolic_bp, dtype: float64
```

Вывод: среднее и медиана немного сдвинулись вправо — заполненные значения явно отличаются от основного распределения. Это и есть цель метода: пропуски не «растворяются» в данных, а остаются заметными.

Задача №29. Удаление константных и псевдоконстантных признаков

Константный признак — все значения одинаковы, дисперсия = 0.
Псевдоконстантный признак — почти все значения одинаковы, дисперсия очень мала.

Такие признаки не несут полезной информации для модели и должны быть удалены.

Используем `VarianceThreshold` из `sklearn` — удаляет признаки, у которых дисперсия ниже заданного порога.

In [11]:
```
# Работаем с заполненным датасетом (без пропусков)
# Проверяем уникальные значения и дисперсию каждого признака
for col in df_filled.columns:
    n_unique = df_filled[col].nunique()
    variance = df_filled[col].var()
    print(f'{col:20s}  unique={n_unique:4d}  var={variance:.4f}')
```

```
age                   unique=  60  var=300.5363
systolic_bp           unique= 425  var=810.5992
bmi                   unique= 497  var=23.6823
glucose               unique= 500  var=1675.1965
heart_rate            unique= 497  var=135.3472
region_code           unique=   1  var=0.0000
test_version          unique=   2  var=0.0310
hospital_flag         unique=   2  var=0.0329
diagnosis             unique=   2  var=0.2128
```

Видим, что:

- `region_code` — 1 уникальное значение, дисперсия = 0 (**константный**)
- `test_version` и `hospital_flag` — 2 уникальных значения, но дисперсия очень мала (**псевдоконстантные**)

In [12]:
```
# Доля преобладающего значения для псевдоконстантных признаков
for col in ['region_code', 'test_version', 'hospital_flag']:
    top_val = df_filled[col].value_counts(normalize=True).iloc[0]
    print(f'{col}: преобладающее значение занимает {top_val:.1%}')
```

```
region_code: преобладающее значение занимает 100.0%
test_version: преобладающее значение занимает 96.8%
hospital_flag: преобладающее значение занимает 96.6%
```

In [13]:
```
# Применяем VarianceThreshold
# threshold=0.05 отсекает признаки, у которых дисперсия < 0.05
selector = VarianceThreshold(threshold=0.05)
selector.fit(df_filled)

# Дисперсия каждого признака
variances = pd.Series(selector.variances_, index=df_filled.columns)
print('Дисперсии признаков:')
print(variances.round(4))
```

```
Дисперсии признаков:
age               299.9352
systolic_bp       808.9780
bmi                23.6350
glucose          1671.8461
heart_rate        135.0766
region_code         0.0000
test_version        0.0310
hospital_flag       0.0328
diagnosis           0.2124
dtype: float64
```

In [14]:
```
# Маска: True — признак оставить, False — удалить
support = selector.get_support()
feature_status = pd.DataFrame({
    'признак': df_filled.columns,
    'дисперсия': variances.values.round(4),
    'оставить': support
})
print(feature_status.to_string(index=False))
```

```
       признак  дисперсия  оставить
           age   299.9352      True
    systolic_bp   808.9780      True
           bmi    23.6350      True
       glucose  1671.8461      True
     heart_rate   135.0766      True
    region_code     0.0000     False
   test_version     0.0310     False
  hospital_flag     0.0328     False
      diagnosis     0.2124      True
```

In [15]:
```
# Признаки, которые будут удалены
removed = list(df_filled.columns[~support])
print('Удаляемые признаки:', removed)
```

```
Удаляемые признаки: ['region_code', 'test_version', 'hospital_flag']
```

In [16]:
```
# Формируем итоговый датасет без константных и псевдоконстантных признаков
df_selected = df_filled[df_filled.columns[support]].copy()
print('Размер датасета ДО отбора:', df_filled.shape)
print('Размер датасета ПОСЛЕ отбора:', df_selected.shape)
df_selected.head()
```

```
Размер датасета ДО отбора: (500, 9)
Размер датасета ПОСЛЕ отбора: (500, 6)
```

Out[16]:

	age	systolic_bp	bmi	glucose	heart_rate	diagnosis
0	58	140.300954	16.590353	107.765083	46.644811	1
1	71	207.054630	35.482282	91.175097	62.883232	1
2	48	141.417810	28.055087	143.268599	82.429851	1
3	34	152.711313	26.516434	162.112654	99.689946	1
4	62	149.080035	24.275405	87.442419	75.249524	1

Вывод: удалены 3 признака — `region_code` (константный, дисперсия = 0), `test_version` и `hospital_flag` (псевдоконстантные). Итоговый датасет содержит только информативные признаки.

Дополнительно. Диаграмма рассеяния

Строим диаграмму рассеяния для пары признаков `glucose` и `systolic_bp`. Точки окрашены по значению целевого признака `diagnosis`.

In [17]:
```
plt.figure(figsize=(8, 5))
colors = {0: 'steelblue', 1: 'tomato'}
labels = {0: 'Нет заболевания', 1: 'Есть заболевание'}

for cls in [0, 1]:
    mask = df_selected['diagnosis'] == cls
    plt.scatter(
```

```
        df_selected.loc[mask, 'glucose'],
        df_selected.loc[mask, 'systolic_bp'],
        c=colors[cls], label=labels[cls], alpha=0.6, edgecolors='white', linewidths
    )

plt.xlabel('Уровень глюкозы (мг/дл)')
plt.ylabel('Систолическое давление (мм рт. ст.)')
plt.title('Диаграмма рассеяния: glucose vs systolic_bp')
plt.legend()
plt.tight_layout()
plt.show()
```